Raport projektu z przedmiotu sztuczna inteligencja

Temat: Zrealizować sieć neuronową uczoną algorytmem wstecznej propagacji błędu z przyśpieszeniem metodą „momentum” (MLP_M) uczącą się identyfikacji szkła.

Wykonał:
Kamil Polit
Nr albumu: 168159
3EF-ZI
Grupa:2
Rok 2023

Spis treści:

1. Opis problemu

Praca nad projektem zakłada utworzenie sieci neuronowej przy użyciu algorytmu wstecznej propagacji błędu. Następnie sieć ta zostanie poddana procesowi nauki, w którym zastosowane zostanie przyspieszenie za pomocą metody "momentum" w celu identyfikacji szkła. Przy wykorzystaniu tej sieci przeprowadzone zostaną eksperymenty, których celem będzie ustalenie, jak poszczególne współczynniki wpływają na skuteczność procesu identyfikacji.

2. Część teoretyczna

2.1. Model neuronu

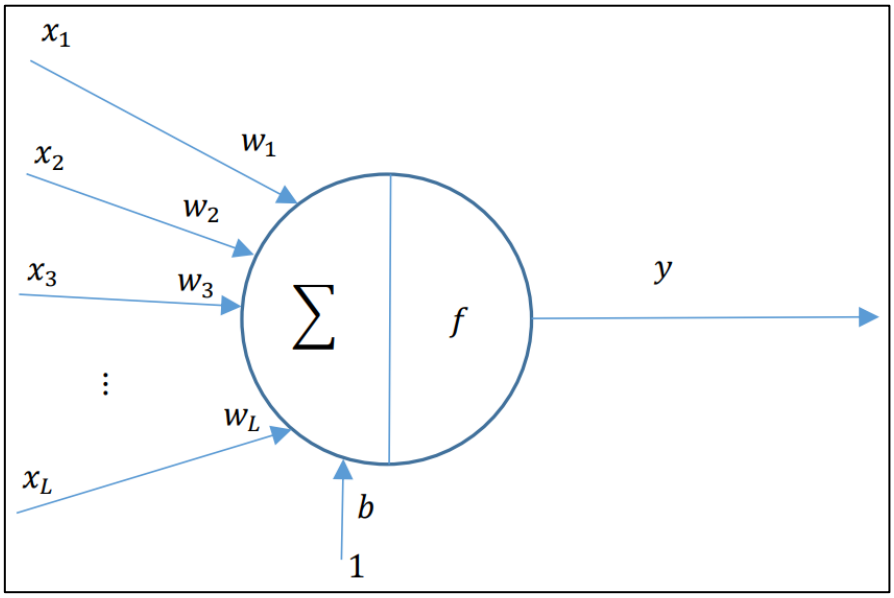

Rys. 1. Model neuronu

Sygnał wyjściowy neuronu y określony jest zależnością:

$$y = f\left(\sum_{j=1}^{L} w_j x_j + b\right) \tag{1}$$

gdzie x_j jest j-tym (j = 1,2,…,L) sygnałem wejściowym, a w_j - współczynnikiem wagowym (wagą). Ze względu na skrócenie zapisu wygodnie będzie stosować zapis macierzowy do opisu działania neuronu. Niech $x = [x_1, x_2, x_L]^T$ będzie wektorem sygnałów wejściowych, $w = [x_1, x_2, \dots, x_L]^T$ - macierzą wierszową wag, a y i b - skalarami.

Wówczas

$$y = f(w \cdot x + b) \tag{2}$$

Ważona suma wejść wraz z przesunięciem często bywa nazywana łącznym pobudzeniem neuronu i w dalszych rozważaniach oznaczana będzie symbolem z

$$z = \sum_{j=1}^{L} w_j x_j + b \tag{3}$$

2.2. Sieci neuronowe jednokierunkowe wielowarstwowe

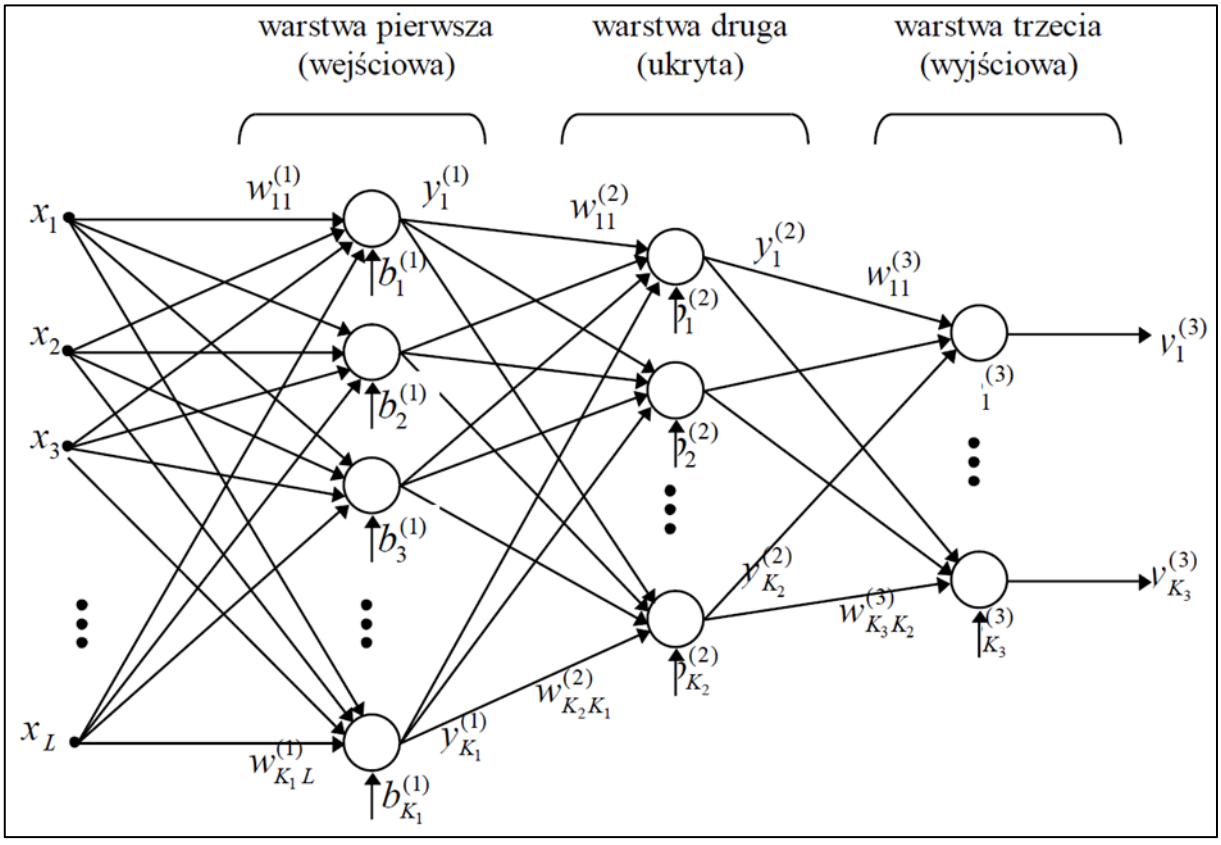

Rys. 2. Sieć jednokierunkowa wielowarstwowa

Taką sieć nazywa się trójwarstwową. Występują tu połączenia pomiędzy warstwami neuronów typu każdy z każdym. Sygnały wejściowe podawane są do warstwy wejściowej neuronów, których wyjścia stanowią sygnały źródłowe dla kolejnej warstwy. Można wykazać, że sieć trójwarstwowa nieliniowa jest w stanie odwzorować praktycznie dowolne odwzorowanie nieliniowe.

Każda warstwa neuronów posiada swoją macierz wag $\boldsymbol{w}$, wektor przesunięć $\boldsymbol{b}$, funkcje aktywacji $\boldsymbol{f}$ i wektor sygnałów wyjściowych $\boldsymbol{y}$. Aby je rozróżniać w dalszych rozważaniach do każdej z wielkości dodano numer warstwy, której dotyczą. Na przykład dla warstwy drugiej (ukrytej) macierz wag oznaczana będzie symbolem $\boldsymbol{w}(2)$. Działanie każdej z warstw można rozpatrywać oddzielnie. I tak np. warstwa druga posiada: $L = K1$ sygnałów wejściowych, $K = K2$ neuronów i macierz wag $\boldsymbol{w} = \boldsymbol{w}(2)$ o rozmiarach $K2 \times K1$. Wejściem warstwy drugiej jest wyjście warstwy pierwszej $\boldsymbol{x} = \boldsymbol{y}(1)$, a wyjściem $\boldsymbol{y} = \boldsymbol{y}(2)$. Działanie poszczególnych warstw dane jest przez

$$y^{(1)} = f^{(1)}(z^{(1)}) = f^{(1)}(w^{(1)}x + b^{(1)}) \tag{4}$$

$$y^{(2)} = f^{(2)}(z^{(2)}) = f^{(2)}(w^{(2)}y^{(1)} + b^{(2)}) \tag{5}$$

$$y^{(3)} = f^{(3)}(z^{(3)}) = f^{(3)}(w^{(3)}y^{(2)} + b^{(3)}) \tag{6}$$

Działanie całej sieci można, więc opisać, jako:

$$y^{(3)} = f^{(3)}(w^{(3)}f^{(2)}\left(w^{(2)}f^{(1)}\left(w^{(1)}x + b^{(1)}\right) + b^{(2)}\right) + b^{(3)}) \tag{7}$$

Sieci jednokierunkowe wielowarstwowe wykorzystują najczęściej w warstwach wejściowej i ukrytej funkcje aktywacji typu sigmoidalnego. Typ funkcji aktywacji w warstwie wyjściowej zależy od przeznaczenia sieci. W pewnych praktycznych zastosowaniach (np. w sieciach używanych do sterowania) zastosowanie funkcji aktywacji typu sigmoidalnego może być niekorzystne. Istotne znaczenie ma tutaj zbyt wąski zakres (-1,1) sygnału wyjściowego. W związku z tym, w wielu zastosowaniach używa się funkcji liniowej w warstwie wyjściowej, która nie posiada takich ograniczeń.

2.3. Algorytm wstecznej propagacji błędu z przyśpieszeniem metodą „momentum”

Uczenie pod nadzorem sieci wielowarstwowej zostanie przeprowadzone metodą wstecznej propagacji błędu. W przypadku sieci trójwarstwowej z rys.2 funkcja celu (w tym przypadku sumarycznego błędu kwadratowego SSE) $E = SSE = \frac{1}{2}\sum_{i=1}^{K} e_i^2$ po uwzględnieniu zależności (4) - (7) przyjmie postać

$$E = SSE = \frac{1}{2}\sum_{i_3=1}^{K_3} e_{i_3}^2 =$$

$$\frac{1}{2}\sum_{i_3=1}^{K_3}\left(y_{i_3}{}^{(3)} - \hat{y}_{i_3}\right)^2 = \frac{1}{2}\sum_{i_3=1}^{K_3}(f^{(3)}(\sum_{i_2=1}^{K_2} w_{i_3 i_2}{}^{(3)} y_{i_2}{}^{(2)} + b_{i_3}^{(3)}) - \hat{y}_{i_3})^2 =$$

$$\frac{1}{2}\sum_{i_3=1}^{K_3}(f^{(3)}(\sum_{i_2=1}^{K_2} w_{i_3 i_2}{}^{(3)} f^{(2)}(\sum_{i_1=1}^{K_1} w_{i_2 i_1}{}^{(2)} y_{i_1}{}^{(1)} + b_{i_2}^{(2)}) + b_{i_3}^{(3)}) - \hat{y}_{i_3})^2 = \tag{8}$$

$$\frac{1}{2}\sum_{i_3=1}^{K_3}(f^{(3)}(\sum_{i_2=1}^{K_2} w_{i_3 i_2}{}^{(3)} f^{(2)}(\sum_{i_1=1}^{K_1} w_{i_2 i_1}{}^{(2)} f^{(1)}\left(\sum_{j=1}^{L} w_{i_1 j}{}^{(1)} x_j + b_{i_1}^{(1)}\right) + b_{i_2}^{(2)}) + b_{i_3}^{(3)}) - \hat{y}_{i_3})^2$$

gdzie: j = 1, … , L oznacza numer wejścia warstwy pierwszej, $i1$ = 1, … , $K1$, $i2$ =1, … , $K2$, $i3$ = 1, … , $K3$ – oznaczają odpowiednio numer wyjścia warstwy pierwszej, drugiej i trzeciej.

Odpowiednie składniki gradientu funkcji celu względem wag neuronów poszczególnych warstw otrzymuje się przez różniczkowanie zależności (8). Obliczanie wag neuronów rozpoczyna się od warstwy wyjściowej, dla której mamy

$$\frac{\partial E}{\partial w_{i_3 i_2}^{(3)}} = \frac{\partial E}{\partial y_{i_3}^{(3)}} \frac{\partial y_{i_3}^{(3)}(z_{i_3}^{(3)})}{\partial z_{i_3}^{(3)}} \frac{\partial z_{i_3}^{(3)}}{\partial w_{i_3 i_2}^{(3)}} = (y_{i_3}^{(3)} - \hat{y}_{i_3}) \frac{\partial y_{i_3}^{(3)}(z_{i_3}^{(3)})}{\partial z_{i_3}^{(3)}} y_{i_2}^{(2)} \tag{9}$$

gdzie:

$$z_{i_3}^{(3)} = \sum_{i_2=1}^{K_2} (w_{i_3 i_2}{}^{(3)} y_{i_2}{}^{(2)} + b_{i_3}^{(3)}) \tag{10}$$

jest łącznym pobudzeniem $i3$-tego neuronu warstwy wyjściowej. Stosując podstawienie:

$$\delta_{i_3}^{(3)} = (y_{i_3}{}^{(3)} - \hat{y}_{i_3}) \frac{\partial y_{i_3}^{(3)}(z_{i_3}^{(3)})}{\partial z_{i_3}^{(3)}} \tag{11}$$

zależność przyjmie postać:

$$\frac{\partial E}{\partial w_{i_3 i_2}^{(3)}} = \delta_{i_3}^{(3)} y_{i_2}{}^{(2)} \tag{12}$$

Podobnie można wyznaczyć elementy gradientu względem wag warstwy ukrytej i wejściowej:

$$\frac{\partial E}{\partial w_{i_2 i_1}^{(2)}} = \frac{\partial E}{\partial y_{i_3}^{(3)}} \frac{\partial y_{i_3}^{(3)}(z_{i_3}^{(3)})}{\partial z_{i_3}^{(3)}} \frac{\partial z_{i_3}^{(3)}}{\partial y_{i_2}^{(2)}} \frac{\partial y_{i_2}^{(2)}(z_{i_2}^{(2)})}{\partial z_{i_2}^{(2)}} \frac{\partial z_{i_2}^{(2)}}{\partial w_{i_2 i_1}^{(2)}} = z_{i_3}^{(3)} \tag{13}$$

$$= \sum_{i_3=1}^{K_3} (y_{i_3}{}^{(3)} - \hat{y}_{i_3}) \frac{\partial y_{i_3}{}^{(3)}(z_{i_3}^{(3)})}{\partial (z_{i_3}^{(3)})} w_{i_3 i_2}^{(3)} \frac{\partial y_{i_2}{}^{(2)}(z_{i_2}^{(2)})}{\partial (z_{i_2}^{(2)})} y_{i_1}{}^{(1)} =$$

$$\frac{\partial E}{\partial w_{i_1 j}^{(1)}} = \frac{\partial E}{\partial y_{i_3}^{(3)}} \frac{\partial y_{i_3}^{(3)}(z_{i_3}^{(3)})}{\partial z_{i_3}^{(3)}} \frac{\partial z_{i_3}^{(3)}}{\partial y_{i_2}^{(2)}} \frac{\partial y_{i_2}^{(2)}(z_{i_2}^{(2)})}{\partial y_{i_2}^{(2)}} \frac{\partial z_{i_2}^{(2)}}{\partial z_{i_2}^{(2)}} \frac{\partial y_{i_1}^{(1)}(z_{i_1}^{(1)})}{\partial z_{i_1}^{(2)}} \frac{\partial z_{i_1}^{(1)}}{\partial w_{i_1 j}^{(1)}} =$$

$$\sum_{i_3=1}^{K_3} (y_{i_3}{}^{(3)} - \hat{y}_{i_3}) \frac{\partial y_{i_3}{}^{(3)}(z_{i_3}^{(3)})}{\partial (z_{i_3}^{(3)})} \sum_{i_2=1}^{K_2} w_{i_3 i_2}{}^{(3)} \frac{\partial y_{i_2}^{(2)}(z_{i_2}^{(2)})}{\partial y_{i_2}^{(2)}} w_{i_2 i_1}{}^{(2)} \frac{\partial y_{i_1}^{(1)}(z_{i_1}^{(1)})}{\partial y_{i_1}^{(1)}} x_j \tag{14}$$

Analogicznie można wyznaczyć elementy gradientu względem przesunięć w poszczególnych warstwach sieci.

Zależności (11), (13) i (14) po podstawieniu do:

$$w_{ij}(t+1) = w_{ij}(t) + \Delta w_{ij}(t) \tag{15}$$

pozwalają na uczenie odpowiednio warstw trzeciej, drugiej i pierwszej trójwarstwowej sieci neuronowej.

Do przyspieszania uczenia zostanie wykorzystana metoda „momentum”. W przypadku uczenia pod nadzorem modyfikacji gradientowej reguły uczenia (15) do postaci przyśpieszania metodą momentum może wyglądać następująco:

$$w_{ij}(t + 1) = w_{ij}(t) + \Delta w_{ij}(t) + mcM_{ij}(t) \tag{16}$$

gdzie $\boldsymbol{\Delta w_{ij}(t)}$ jest określone zależnością:

$$\Delta w = -\eta \nabla E(w) \tag{17}$$

w której $\boldsymbol{\partial E/\partial w_{ij}}$ dla poszczególnych warstw sieci wielowarstwowej uwzględnia (9), (13) i (14), zaś składnik momentum $M_{ij}(t)$ jest wyliczany z zależności

$$M_{ij}(\mathrm{t}) = w_{ij}(\mathrm{t}) - w_{ij}(\mathrm{t} - 1) \tag{18}$$

$m_c \in [0,1]$ jest współczynnikiem momentum. Jeżeli m_c = 0, to reguła (16) upraszcza się do (15). Najczęściej przyjmuje się m_c = 0.95. Wprowadzenie składnika momentum zdecydowanie wpływa na zwiększenie szybkości uczenia.

3. Analiza danych

Informacje na temat danych:

- Ilość przypadków: 214
- Ilość atrybutów: 9
- Zadanie: Klasyfikacja
- Brakujących danych: 0

Dane zostały podzielone na 11 kolumn, z których pierwsza zawiera unikalne identyfikatory przypadków. W drugiej kolumnie znajduje się współczynnik załamania. Kolumny od 4 do 10 przedstawiają procentowe udziały poszczególnych składników chemicznych (sodu, magnezu, aluminium, silikonu, potasu, wapnia, baru oraz żelaza). Jedenasta kolumna zawiera informacje o rodzaju szkła. Możemy sklasyfikować 7 różnych rodzajów szkła: procesowane szkło do budowy okien, nieprocesowane szkło do budowy okien, procesowane szkło używane w pojazdach, nieprocesowane szkło używane w pojazdach, pojemniki, zastawa stołowa, szkło do reflektorów.

1. Tabela - Dystrybucja w klasach

Nazwa klasy	Ilość elementów
Używanych w oknach (budynków lub pojazdów)	163
-Procesowanych	87
--Szkło do budowy okien	70
--Szkło używane w pojazdach	17
-Nieprocesowanych	76
--Szkło do budowy okien	76
--Szkło używane w pojazdach	0
Nieprocesowanych	51
-Szkło do budowy okien	13
-Szkło używane w pojazdach	9
-Nie jest używanych w oknach	29

Link do strony, z której pochodzą dane znajduje się w bibliografii.

4. Kod programu

```
1)  import hickle as hkl                          # Biblioteka do obsługi plików binarnych
2)  import numpy as np                            # Biblioteka do obliczeń naukowych i numerycznych
3)  import nnet as net                            # Biblioteka zawierająca funkcje sieci neuronowych
4)  import matplotlib.pyplot as plt               # Biblioteka do tworzenia wykresów
5)  from sklearn.model_selection import StratifiedKFold # Klasa do podziału danych na zbiory testowe i treningowe
6)  from timeit import default_timer as timer     # Klasa timer do sprawdzania sekund od startu
7)                                                # Linie 1-6: implementacja bibliotek i metod
8)  class mlp_m_3w:
9)      def __init__(self, x, y_t, K1, K2, lr, err_goal, \
10)                 disp_freq, mc, max_epoch, initialize): # Linia 9: Inicjalizacja konstruktora
11)                                                          klasy z przekazanymi argumentami
12)         self.x            = x                 # Dane wejściowe
13)         self.L            = self.x.shape[0]   # Liczba cech wejściowych
14)         self.y_t          = y_t               # Oczekiwane dane wyjściowe
15)         self.K1           = K1                # Liczba neuronów w pierwszej warstwie ukrytej
16)         self.K2           = K2                # Liczba neuronów w drugiej warstwie ukrytej
17)         self.lr           = lr                # Współczynnik uczenia (wpływa na tempo aktualizacji wag sieci)
18)         self.err_goal     = err_goal          # Wartość błędu, której chcemy osiągnąć w trakcie uczenia
19)         self.disp_freq    = disp_freq         # Częstotliwość wyświetlania informacji o postępie uczenia
20)         self.mc           = mc                # Współczynnik momentum
21)         self.max_epoch    = max_epoch         # Maksymalna liczba epok (iteracji) uczenia
22)         self.K3           = y_t.shape[0]      # Liczba neuronów w warstwie wyjściowej
23)         self.SSE_vec       = []               # Wektor przechowujący wartości błędu SSE w kolejnych epokach
24)         self.PK_vec        = []               # Wektor przechowujący wartości błędu PK w kolejnych epokach
25)         self.data         = self.x.T          # Dane wejściowe przekształcone (transponowane)
26)         self.target       = self.y_t          # Oczekiwane dane wyjściowe
27)         self.initialize   = initialize        # Flaga wskazująca, czy należy zainicjalizować wagi
28)
29)         if self.initialize:       # Inicjalizacja wag w przypadku, gdy flaga initialize jest ustawiona
30)            self.w1, self.b1 = net.nwtan(self.K1, self.L)
31)            self.w2, self.b2 = net.nwtan(self.K2, self.K1)            # Linie 30-32: inicjalizacja wag
32)            self.w3, self.b3 = net.rands(self.K3, self.K2)
33)            # hkl.dump([self.w1,self.b1,self.w2,self.b2,self.w3,self.b3], 'wagi3w.hkl')
34)         else:                     # Wczytanie wag z pliku w przeciwnym razie
35)            self.w1,self.b1,self.w2,self.b2,self.w3,self.b3 = hkl.load('wagi3w.hkl')
36)                                   # Inicjalizacja poprzednich wag jako aktualnych wag
37)         self.w1_t_1, self.b1_t_1, self.w2_t_1, self.b2_t_1, self.w3_t_1, self.b3_t_1 = \
38)            self.w1, self.b1, self.w2, self.b2, self.w3, self.b3
39)         self.SSE = 0              # Zainicjowanie sumy kwadratów błędów
40)         self.lr_vec = list()      # Stworzenie pustej listy dla współczynników uczenia
41)                                   # Linie 12-40: zdefiniowanie parametrów klasy
42)
43)     def predict(self,x):          # Funkcja obliczająca wartość wyjściową sieci neuronowej dla podanego
44)                                           wektora wejściowego x poprzez przekształcenie go przez warstwy sieci
45)         n = np.dot(self.w1, x)    # Obliczanie iloczynu skalarnego warstwy 1 i danymi wejściowymi
46)         self.y1 = net.tansig( n,  self.b1*np.ones(n.shape))    # Oblicza wartość funkcji tansig dla
47)                                                                  pierwszej warstwy
48)         n = np.dot(self.w2, self.y1) # Obliczanie iloczynu skalarnego warstwy 2 i wyjścia pierwszej warstwy y1
49)         self.y2 = net.tansig( n,  self.b2*np.ones(n.shape))    # Oblicza wartość funkcji tansig dla
50)                                                                  drugiej warstwy
51)         n = np.dot(self.w3, self.y2) # Obliczanie iloczynu skalarnego warstwy 3 i wyjścia drugiej warstwy y2
52)         self.y3 = net.purelin(n, self.b3*np.ones(n.shape))     # Oblicza wartość funkcji purelin
53)                                                                  dla trzeciej warstwy
54)         return self.y3                                         # Zwrócenie wyjścia z trzeciej warstwy jako wynik
55)
56)     def train(self, x_train, y_train):         # Funkcja train przeprowadza trening sieci neuronowej
57)                                                  przy użyciu algorytmu wstecznej propagacji błędu
58)         for epoch in range(1, self.max_epoch+1):
59)            self.y3 = self.predict(x_train)      # Obliczanie wartości wyjściowej sieci dla danych treningowych
60)            self.e = y_train - self.y3           # Obliczanie błędu predykcji
61)            self.SSE_t_1 = self.SSE
62)            self.SSE = net.sumsqr(self.e) # Obliczanie sumy kwadratów błędów
63)            self.PK = sum((abs(self.e)<0.5).astype(int)[0])/self.e.shape[1] * 100    # Oblicza stopień
64)                                                                                       poprawności predykcji
```

```
65)             self.PK_vec.append(self.PK)                             # Dodanie stopnia poprawności do listy
66)             if self.SSE < self.err_goal or self.PK == 100:
67)                break                                                # Zatrzymanie treningu, jeśli osiągnięto docelowy
68)                                                                      błąd lub stopień poprawności wynosi 100%
69)             if np.isnan(self.SSE):
70)                break                                                # Zatrzymanie treningu, jeśli suma kwadratów
71)                                                                      błędów jest nieokreślona
72)             self.d3 = net.deltalin(self.y3, self.e)                # Obliczanie gradientu dla warstwy wyjściowej
73)             self.d2 = net.deltatan(self.y2, self.d3, self.w3)      # Obliczanie gradientu dla warstwy ukrytej 2
74)             self.d1 = net.deltatan(self.y1, self.d2, self.w2)      # Obliczanie gradientu dla warstwy ukrytej 1
75)             self.dw1, self.db1 = net.learnbp(x_train,  self.d1, self.lr)      # Obliczanie zmiany wag i
76)                                                                                  progów dla w1 i b1
77)             self.dw2, self.db2 = net.learnbp(self.y1,  self.d2, self.lr)      # Obliczanie zmiany wag i
78)                                                                                  progów dla w2 i b2
79)             self.dw3, self.db3 = net.learnbp(self.y2,  self.d3, self.lr)      # Obliczanie zmiany wag i
80)                                                                                  progów dla w3 i b3
81)                     # Próg jest parametrem dodatkowym w sieciach neuronowych, który wpływa na aktywację neuronów
82)             self.w1_temp, self.b1_temp, self.w2_temp, self.b2_temp, self.w3_temp, self.b3_temp = \
83)             self.w1.copy(), self.b1.copy(), self.w2.copy(), self.b2.copy(), self.w3.copy(), self.b3.copy()
84)                     # Tworzy kopię wag i progów
85)                     # Próg jest parametrem dodatkowym w sieciach neuronowych, który wpływa na aktywację neuronów.
86)             self.w1 += self.dw1 + self.mc * (self.w1 - self.w1_t_1)    # Aktualizuje wagi w1 z uwzględnieniem
87)                                                                          momentum
88)             self.b1 += self.db1 + self.mc * (self.b1 - self.b1_t_1)    # Aktualizuje wagi b1 z uwzględnieniem
89)                                                                          momentum
90)             self.w2 += self.dw2 + self.mc * (self.w2 - self.w2_t_1)    # Aktualizuje wagi w2 z uwzględnieniem
91)                                                                          momentum
92)             self.b2 += self.db2 + self.mc * (self.b2 - self.b2_t_1)    # Aktualizuje wagi b2 z uwzględnieniem
93)                                                                          momentum
94)             self.w3 += self.dw3 + self.mc * (self.w3 - self.w3_t_1)    # Aktualizuje wagi w3 z uwzględnieniem
95)                                                                          momentum
96)             self.b3 += self.db3 + self.mc * (self.b3 - self.b3_t_1)    # Aktualizuje wagi b3 z uwzględnieniem
97)                                                                          momentum
98)
99)             self.w1_t_1, self.b1_t_1, self.w2_t_1, self.b2_t_1, self.w3_t_1, self.b3_t_1 = \
100)            self.w1_temp, self.b1_temp, self.w2_temp, self.b2_temp, self.w3_temp, self.b3_temp
101)                                            # Zapisuje poprzednie wagi i progi
102)            self.SSE_vec.append(self.SSE) # Dodaje sumę kwadratów błędów do listy
103)
104)    def train_CV(self, CV, skfold):     # Funkcja wykonuje walidację krzyżową (CV) dla sieci neuronowej
105)        PK_vec = np.zeros(CVN)          # Wektor do przechowywania wartości poprawności (PK) dla każdego foldu CV
106)
107)        for i, (train, test) in enumerate(skfold.split(self.data, np.squeeze(self.target)), start=0):
108)           x_train, x_test = self.data[train], self.data[test]
109)           y_train, y_test = np.squeeze(self.target)[train], np.squeeze(self.target)[test]
110)                                        # Linia 101-103 podział danych na zbiory treningowe i testowe
111)           self.train(x_train.T, y_train.T)     # Trenowanie sieci na zbiorze treningowym
112)           result = self.predict(x_test.T)      # Prognozowanie wyników dla zbioru testowego
113)           n_test_samples = test.size           # Liczba próbek w zbiorze testowym
114)           PK_vec[i] = sum((abs(result - y_test)<0.5).astype(int)[0])/n_test_samples * 100       # Obliczenie PK
115)
116)        PK = np.mean(PK_vec)                    # Obliczenie średniej poprawności dla wszystkich foldów CV
117)        return PK                               # Zwrócenie średniej poprawności klasyfikacji
118)
119) x,y_t,x_norm,x_n_s,y_t_s = hkl.load('glass.hkl')      # Wczytanie danych z pliku 'glass.hkl'
120)
121) max_epoch = 2000                                     # Maksymalna liczba epok treningu
122) err_goal = 0.25                                      # Docelowa wartość błędu (suma kwadratów błędów)
123) disp_freq = 200                                      # Częstotliwość wyświetlania informacji diagnostycznych
124)
125) lr_vec = np.array([1e-2, 1e-3, 1e-4, 1e-5])          # Wektor współczynnika uczenia
126) mc_vec = np.array([0.2, 0.5, 0.6, 0.7, 0.9])         # Wektor współczynnika momentum
127) K1_vec = np.array([1,3,5,7])                        # Wektor wartosci K1 do testów
128) K2_vec = K1_vec                                     # Wektor wartosci K1 do testów
129)
130) start = timer()                                     # Wywołanie funkcji rozpoczynającej timer
131) CVN = 10                                            # Liczba podziałów Cross-Validation
```

```
skfold = StratifiedKFold(n_splits=CVN)                # Inicjalizacja obiektu StratifiedKFold z
                                                        podziałem na CVN części
PK_2D_K1K2 = np.zeros([len(K1_vec),len(K2_vec)])      # Inicjalizacja macierzy PK_2D_K1K2
PK_2D_lrmc = np.zeros([len(lr_vec),len(mc_vec)])      # Inicjalizacja macierzy PK_2D_lrmc
PK_2D_K1K2_max = 0                                    # Inicjalizacja maksymalnej wartości PK
                                                        z macierzy PK_2D_K1K2
k1_ind_max = 0                                        # Indeks K1 dla maksymalnej wartości PK
k2_ind_max = 0                                        # Indeks K2 dla maksymalnej wartości PK
for k1_ind in range(len(K1_vec)):       # Pętle iterujące po indeksach w wektorach K1_vec oraz K2_vec
    for k2_ind in range(len(K2_vec)):
        mlpnet = mlp_m_3w(x_norm, y_t, K1_vec[k1_ind], K2_vec[k2_ind],  \
                          lr_vec[1], err_goal, disp_freq, mc_vec[1], \
                              max_epoch, True)      # Inicjalizacja obiektu mlpnet klasy mlp_a_3w
        PK = mlpnet.train_CV(CVN, skfold)       # Wywołanie metody train_CV obiekctu mlpnet do obliczenia PK
        print("K1 {} | K2 {} | PK {}". format(K1_vec[k1_ind], K2_vec[k2_ind], PK))
                                        # Wyświetlenie informacji o wartości PK dla danego K1 i K2
        PK_2D_K1K2[k1_ind, k2_ind] = PK  # Wpisanie wartości PK do odpowiedniej komórki w macierzy PK_2D_K1K2
        if PK > PK_2D_K1K2_max:
           PK_2D_K1K2_max = PK
           k1_ind_max = k1_ind
           k2_ind_max = k2_ind          # Aktualizacja maksymalnej wartości PK oraz indeksów K1 i K2

fig = plt.figure(figsize=(8, 8))                                # Utworzenie figury
ax = fig.add_subplot(111, projection='3d')                      # Dodanie figury do podplotu
X, Y = np.meshgrid(K1_vec, K2_vec)                              # Utworzenie siatki z wartości K1 i K2
surf = ax.plot_surface(X, Y, PK_2D_K1K2.T, cmap='viridis')    # Utworzenie powierzchni z wartości K1,K2 i PK
ax.set_xlabel('K1')
ax.set_ylabel('K2')                                             # Linie 158-160 Dodanie oznaczeń osi
ax.set_zlabel('PK')
ax.view_init(30, 200)
plt.savefig("Fig.1_PK_K1K2_iris.png",bbox_inches='tight')     # Zapisanie zdjęcia figury

PK_2D_lrmc_max = 0                      # Inicjalizacja maksymalnej wartości wskaźnika PK
lr_ind_max = 0                          # Inicjalizacja indeksu najlepszego współczynnika uczenia
mc_ind_max = 0                          # Inicjalizacja indeksu najlepszego współczynnika momentum

for lr_ind in range(len(lr_vec)):       # Pętle iterujące po indeksach w wektorach lr_vec oraz mc_vec
    for mc_ind in range(len(mc_vec)):
        mlpnet = mlp_m_3w(x_norm, y_t, K1_vec[k1_ind_max], K2_vec[k2_ind_max],  \
                          lr_vec[lr_ind], err_goal, disp_freq, mc_vec[mc_ind], \
                             max_epoch, True)       # Inicjalizacja obiektu mlpnet klasy mlp_a_3w
        PK = mlpnet.train_CV(CVN, skfold)       # Wywołanie metody train_CV obiekctu mlpnet do obliczenia PK
        print("lr {} | mc {} | PK {}".format(lr_vec[lr_ind], mc_vec[mc_ind], PK))
                                        # Wyświetlenie informacji o wartości PK dla danego lr i mc
        PK_2D_lrmc[lr_ind, mc_ind] = PK  # Wpisanie wartości PK do odpowiedniej komórki w macierzy PK_2D_lrmc
        if PK > PK_2D_lrmc_max:
           PK_2D_lrmc_max = PK
           lr_ind_max = lr_ind
           mc_ind_max = mc_ind          # Aktualizacja maksymalnej wartości PK oraz indeksów lr i mc

fig = plt.figure(figsize=(8, 8))                                # Utworzenie figury
ax = fig.add_subplot(111, projection='3d')                      # Dodanie figury do podplotu
X, Y = np.meshgrid(lr_vec, mc_vec)                              # Utworzenie siatki z wartości lr i mc
surf = ax.plot_surface(np.log10(X), Y, PK_2D_lrmc.T, cmap='viridis')       # Utworzenie powierzchni z
                                                                             wartości lr, mc i PK
ax.set_xlabel('log10(lr)')
ax.set_ylabel('mc')                                             # Linie 187-189 Dodanie oznaczeń osi
ax.set_zlabel('PK')
ax.view_init(30, 200)
plt.savefig("Fig.2_PK_lrmc_iris.png",bbox_inches='tight')     # Zapisanie zdjęcia figury

print("OPTYMALNE WARTOŚCI: K1={} | K2={} | lr={} | mc={} | PK={}".\
    format(K1_vec[k1_ind_max], K2_vec[k2_ind_max], lr_vec[lr_ind_max], \
       mc_vec[mc_ind_max], PK_2D_lrmc[lr_ind_max, mc_ind_max]))              # Wyświetlanie danych optymalnych
print("Execution time:", timer()-start)
```

5. Eksperymenty

5.1 Wyznaczenie optymalnych wartości K1 oraz K2

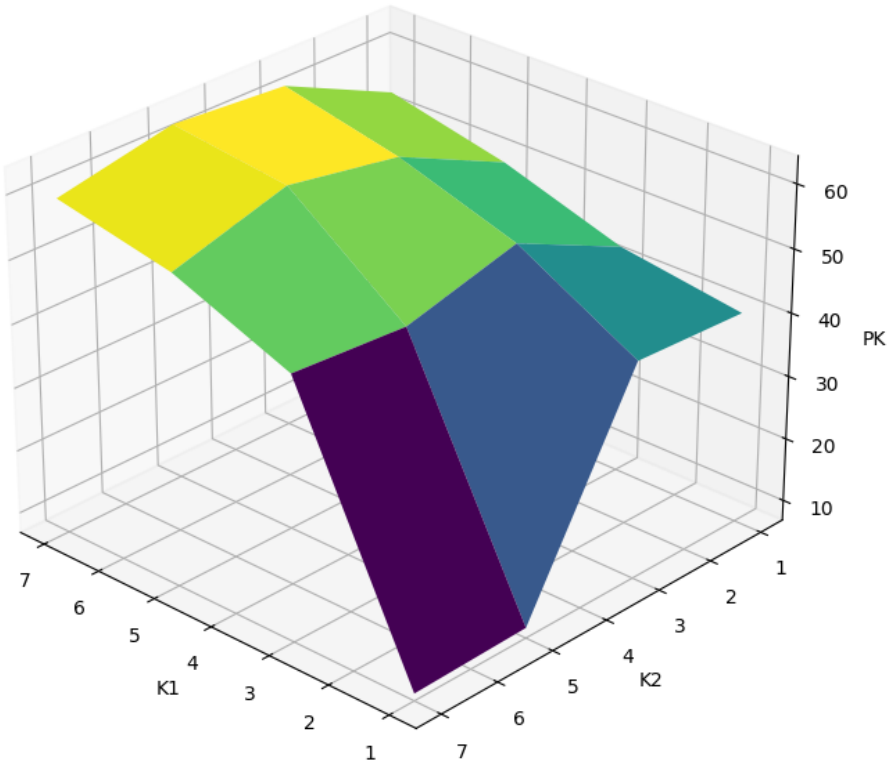

Rys. 3. Płaszczyzna wartości K1,K2 oraz PK

2. Tabela zależności PK od wartości K1 oraz K2				
K1	K2	lr_vec	mc_vec	PK
1	3	1e-3	0.5	41.0822510822511
1	5	1e-3	0.5	8.4199134199134
1	7	1e-3	0.5	7.9437229437229
5	3	1e-3	0.5	57.5974025974026
5	5	1e-3	0.5	60.8658008658009
7	5	1e-3	0.5	63.1168831168831

Z powyższego zdjęcia oraz tabeli wywnioskować możemy tendencję, że im większe wartości K1 oraz K2 przydzielimy tym lepszego wyniku PK możemy się spodziewać. W większości przypadków będzie to prawda, aczkolwiek zauważyć musimy bardzo niskie wyniki dla wartości K1=1 i K2=5 oraz K1=1 i K2=7 ponieważ mogą one przeczyć naszemu wnioskowi. Możemy jednak stwierdzić że są one wynikiem czynników losowych, ponieważ taka tendencja nie pojawiają się w dalszych wynikach.

5.2 Wyznaczenie optymalnych wartości lr oraz mc

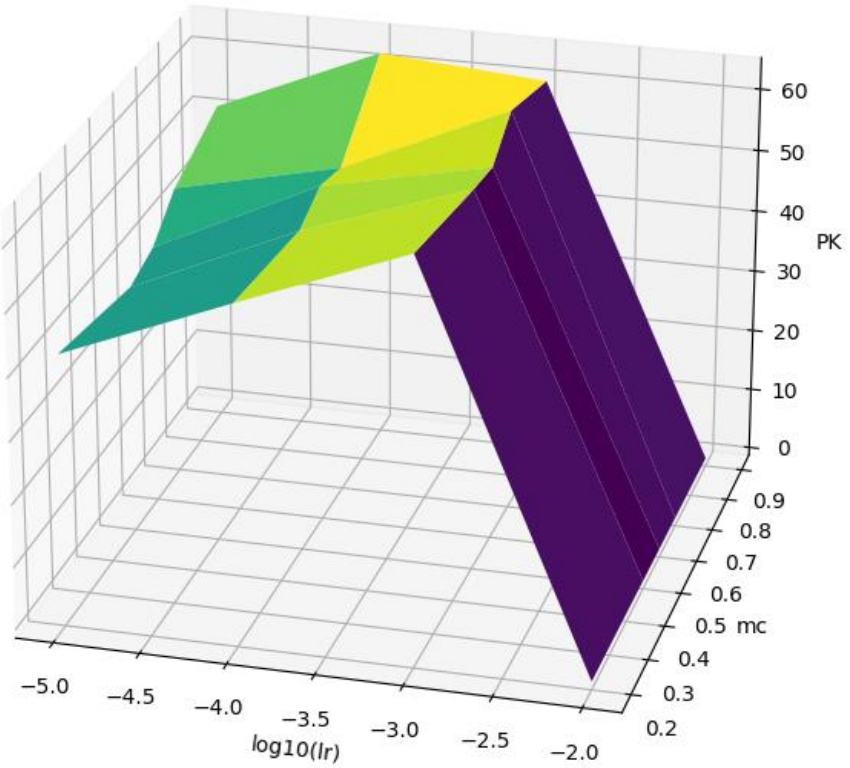

Rys. 4. Płaszczyzna wartości log10(Ir), mc oraz PK

3. Tabela zależności PK od wartości lr oraz mc				
K1	K2	lr_vec	mc_vec	PK
7	5	1e-2	0.2	0.0
7	5	1e-3	0.6	59.0259740259740
7	5	1e-3	0.7	63.7662337662337
7	5	1e-3	0.9	60.2813852813852
7	5	1e-4	0.6	53.3549783549783
7	5	1e-4	0.7	51.9264069264069
7	5	1e-4	0.9	62.3160173160173
7	5	1e-5	0.5	38.7445887445887
7	5	1e-5	0.7	45.9090909090909

Jak widać na powyższym wykresie oraz tabeli najlepszy wynik PK otrzymujemy gdy Ir przyjmuje wartość 1e-3 lub 1e-4. Widzimy również, że zwiększanie lub zmniejszanie wartości lr (1e-2 i 1e-5) drastycznie zmniejszają naszą dokładność. Nie jesteśmy jednak w stanie stwierdzić czy istnieje tendencja dla wartości mc. Trudno jest więc stwierdzić jak dokładnie wartość mc wpływa na nasza skuteczność, możemy się jednak domyślać, że powinniśmy próbować dopasować wartość mc do innych zmiennych.

6. Podsumowanie i wnioski

Podsumowując cel projektu został zrealizowany, utworzyliśmy sieć neuronową tak aby była ona w stanie identyfikować szkło na podstawi podanych atrybutów szkła. Osiągnęła ona skuteczność wynoszącą (przy optymalnych zmiennych) w przybliżeniu 63.766%. W naszych eksperymentach wykazaliśmy zależność, w której ilości neuronów koreluje ze zwiększeniem dokładności skryptu. Upraszczając zwiększanie ilości neuronów może prowadzić do lepszych wyników PK. Jednakże mogą wystąpić przypadki gdy nasza skuteczność drastycznie spadnie (tak jak w przypadku 1 testu dla wartości K1=1 i K2=5 oraz K1=1 i K2=7) pomimo zwiększenia ilości neuronów otrzymaliśmy drastycznie mniejszą skuteczność. Takie zachowanie możemy jednak wytłumaczyć czynnikiem losowym na co wskazywał by fakt, że taka anomalia nie pojawia się w dalszych wynikach. W przypadku lr widzimy, że nasza skuteczność jest największa dla wartości lr=1e-3 oraz lre-4. Zauważyć też możemy, że ani zmniejszanie ani zwiększanie tych wartości nie poprawia naszej skuteczności (test 2 z wartościami lr=1e-2 oraz lr=1e-5). Możemy więc założyć, że są to najbardziej optymalne wartości dla naszych danych wejściowych. Takich zależności nie możemy jednak zauważyć w przypadku mc. Z naszych eksperymentów wynika że wpływ czynnika momentum na naszą skuteczność nie przedstawia konkretnego trendu. Możliwe jest więc że aby uzyskać optymalny wynik PK musimy dopasować wartość mc do pozostałych zmiennych.

7. Bibliografia

Dr hab. inż. prof. PRz Roman Zajdel – instrukcje do laboratoriów:
http://materialy.przrzeszow.pl/pracownik/pliki/34/%C4%86WICZENIE%204.pdf

(dostęp: 12.06.2023)
http://materialy.przrzeszow.pl/pracownik/pliki/34/%C4%86WICZENIE%207.pdf

(dostęp: 12.06.2023)

http://materialy.przrzeszow.pl/pracownik/pliki/34/%C4%86WICZENIE%208.pdf

(dostęp: 12.06.2023)

Dane użyte w testach pobrane zostały ze strony:

http://archive.ics.uci.edu/dataset/42/glass+identification

(dostęp: 12.06.2023)